

ІТМО

Разработка энергоэффективной системы распознавания голосовых команд с использованием нейронных сетей для устройств интернета вещей

Выполнил:

студент группы Р3431
Дворкин Борис Александрович

Научный руководитель:

Быковский Сергей Вячеславович

Проблема: IoT устройства с распознаванием речи потребляют много энергии, как следствие имеют низкую автономность батарейных модулей и необходимость в частом техническом обслуживании, либо стационарном источнике питания.



Нишевые сценарии, где важна энергоэффективность:

- Автономная робототехника
- Промышленные Hands-free интерфейсы
- Распределенные охранные узлы
- Полевые IoT-датчики и сельхозтехника
- Медицинские носимые устройства

Обзор решений

Edge AI: Специальные ASIC

- Syntiant NDP101
- Ambiq Apollo4+

- ✓ Идеально выполняют свою задачу
- ✗ Стоимость, гибкость, “чёрный ящик”

Edge AI: МК общего назначения

- **ESP32 S3**
- STM32H7

- ✓ Доступность, открытость, гибкость
- ✗ Уступают ASIC в энергоэффективности

Cloud AI: Облачные решения

Экосистема:

- Amazon Alexa
- Google Assistant
- Apple Siri
- Яндекс Алиса

+

Технология в облаке:

- Яндекс SpeechKit
- Google Cloud Speech-To-Text
- Microsoft Azure Speech
- Amazon Transcribe

- ✓ Стоимость, распознавание речи
- ✗ Задержки, интернет, приватность

Цель

ІІТМО


Снизить энергопотребление системы распознавания речи на IoT-устройствах за счёт использования квантизированных нейронных сетей и оптимизации режимов работы микроконтроллера



1. Провести анализ существующих методов оптимизации энергопотребления IoT-систем, платформ с распознаванием речи
2. Спроектировать и собрать измерительный стенд с изолированными доменами питания для экспериментального исследования энергопотребления
3. Разработать прошивку для микроконтроллера с интеграцией MEMS микрофона и квантизированной нейронной сети, управлением питания периферии и режимами работы глубокого сна, лёгкого сна и активного инференса, на примере платформы ESP32-S3
4. Реализовать систему логирования энергопотребления на базе ESP32-C3 и датчика INA219/INA228
5. Провести экспериментальные измерения и сравнительный анализ в режимах активного инференса, лёгкого и глубокого сна, а также локальной обработки голоса на устройстве и передачи в облако по метрикам энергопотребления, латентности и надёжности.
6. Исследовать влияние метода квантизации нейронной сети на точность распознавания, размер модели и энергопотребление при инференсе
7. Оценить эффективность применённых методов оптимизации и сформулировать рекомендации по проектированию энергоэффективных IoT-систем с голосовым управлением



Уже сделано



- Обзор предметной области
- Обоснован выбор ESP32-S3, изучены фреймворки
- Спроектирована и собрана схема тестового стенда
- Разработан драйвер I2S для микрофона INMP441, отлажен аудиопайплайн
- Интегрирована WakeNet9s (DS-CNN), протестирована детекция узкого набора ключевых слов
- Выявлено высокое потребление микрофона

- Программа логгера ESP32-C3 + INA219/INA228 с передачей данных на ПК, базовые измерения по всем режимам (deep sleep, light sleep, active inference)
- Python-скрипт визуализации профилей потребления
- Реализация MOSFET-гейтинга питания микрофона + детектор активности на ULP
- Измерения оптимизированной системы, сравнение с baseline
- Сравнительный эксперимент: локальная обработка vs передача в облако
- Исследование PTQ/QAT: влияние метода квантизации на точность и потребление
- Написание и оформление ВКР (главы 1–4, заключение, презентация)



Практический результат:



1. Работающий прототип системы голосового управления на ESP32-S3 с аппаратным управлением питанием микрофона и режимами сна
2. Квантизированная нейросетевая модель (DS-CNN, PTQ/QAT INT8) для распознавания ключевых слов, задеплоенная на устройстве
3. Экспериментально подтвержденное снижение *среднего тока ожидания (idle)* с ~1.4 мА до <0.1 мА

Готовность: ~35%

**Спасибо
за внимание!**

itMO *re than a*
UNIVERSITY

tg: @worthant
mail: boris0indeed@gmail.com