

ІТМО

Разработка энергоэффективной системы распознавания голосовых команд с использованием нейронных сетей для устройств интернета вещей

Выполнил:

студент группы Р3431
Дворкин Борис Александрович

Научный руководитель:

Быковский Сергей Вячеславович

Проблема: IoT-устройства с KWS потребляют много энергии, в результате чего получаем низкую автономность батарейных модулей, необходимость в частом тех. обслуживании, либо стационарном источнике питания.

← моя работа

Cloud AI

Alexa, Siri, Алиса

Полная зависимость от интернета, нет приватности, питание от сети

Edge AI: ASIC

Syntiant NDP, Ambiq

Микроваттный инференс, но дорого, закрыто, «черный ящик»


Edge AI: MCU

STM32, nRF, ESP32

Доступность, открытость, гибкость.
Уступают asic в конкретных задачах.

Цель работы

Снижение энергопотребления системы распознавания ключевых слов на устройствах интернета вещей за счёт применения каскадной декомпозиции процесса детекции ключевых слов на этапы с возрастающей вычислительной сложностью и применения квантизации нейросетевой модели.




Каскадная архитектура: каждый этап активируется только при необходимости

1. Провести анализ существующих методов и систем распознавания ключевых слов на ресурсограниченных устройствах, выявить основные источники избыточного энергопотребления в режиме непрерывного голосового мониторинга и сформулировать требования к энергоэффективному решению.
2. Предложить каскадную архитектуру детекции ключевых слов, разделяющую процесс на этапы с возрастающей вычислительной сложностью и управлением режимами энергопотребления, допускающую реализацию на различных микроконтроллерных платформах.
3. Исследовать влияние методов квантизации (PTQ, QAT) на точность, размер и вычислительную сложность нейросетевой модели классификатора ключевых слов.
4. Провести экспериментальную апробацию предложенного подхода на микроконтроллерной платформе ESP32-S3 с использованием разработанного измерительного стенда.
5. Выполнить сравнительную оценку энергоэффективности предложенного решения относительно базовых сценариев и проанализировать вклад каждого компонента архитектуры в общее снижение энергопотребления.




Результаты: каскадная архитектура



- Собран прототип с каскадным пробуждением: deep sleep → sound → KWS → deep sleep, на основе платформы ESP32-S3.
- Разработан драйвер I2S для микрофона INMP441, отлажен аудиопайплайн, настроен пороговый датчик звука, периферия RTC домена.
- Интегрирована WakeNet9s (DS-CNN) и собственная обученная модель DS-CNN M.
- Протестирована детекция заданного набора ключевых слов, сделаны замеры энергопотребления.

Результаты: квантизация модели



— ×

	Точность	F1-мера	Размер	Сжатие
DS-CNN M FP32	96.46%	95.25%	956 KB	—
DS-CNN M QAT INT8	96.29%	95.30%	261 KB	×3.7
DS-CNN M PTQ INT8	96.15%	95.14%	261 KB	×3.7

Исправления и план

Исправлено, сделано

- ✓ Переформулировал цель: конкретизировал метод каскадной детекции, определил измеримые критерии оценки.
- ✓ Переписал задачи - от проблемы через решение к апробации (а не от реализации), убрал “оптимальность” и “эффективность”.
- ✓ Обучил свою модель DS-CNN M, добился назначенных критериев эффективности (f1-мера и точность после квантования >95%, сжатие >3).
- ✓ Провёл декомпозицию энергобюджета, классифицировал источники энергопотерь, сделал замеры на стенде & расчёт для целевой конфигурации по даташитам.

Осталось сделать


- Дообучение, оптимизация, повторный деплой DS-CNN модели под платформу ESP32-S3 через TFLite Micro.
- Замеры задержек, их влияния и энергозатрат своей модели на целевой платформе.
- Сравнение DS-CNN INT8 с базовым сценарием непрерывного инференса по энергопотреблению, сравнение с другими архитектурами из литературы.
- Написание и оформление текста ВКР.

ГОТОВНОСТЬ

Практическая часть



Текст ВКР



Структура ВКР

Раздел 1

Анализ предметной области

Обзор архитектур KWS, методов компрессии, подходов к снижению энергопотребления на ресурсограниченных устройствах. Постановка проблемы и требований.

Раздел 2

Проектирование каскадной архитектуры

Архитектура каскадной детекции ключевых слов с многоуровневым управлением режимами энергопотребления. Выбор, анализ, оценка.

Раздел 3

Реализация и апробация

Обучение и квантизация нейросетевой модели, разработка встраиваемого ПО, реализация прототипа и измерительного стенда. Методика измерений.

Раздел 4

Анализ результатов


Декомпозиция энергобюджета, сравнительный анализ режимов работы и моделей с Базисом. Применимость к другим платформам. Оценка предложенного решения.

**Спасибо
за внимание!**

iT's **MO** *re than a*
UNIVERSITY

tg: @worthant
mail: boris0indeed@gmail.com

Размещение компонентов на тестовом стенде



- inmp441 - i2s mems-микрофон
- ina228 - цифровой “мультиметр”
- esp32-s3-zero - отладочная плата для удобной работы с чипом esp32-s3 (usb phy, кнопки reset/boot, монтажные ножки)
- s3 имеет архитектуру Xtensa LX7 с поддержкой SIMD (128-битные регистры, можем одной инструкцией делать 8 умножений по 8 пар при INT8 квантизации!)
- esp32-c3-super-mini - отладочная плата для удобной работы с чипом esp32-c3.
- c3 имеет открытую архитектуру RISC-V. В данном случае используемый MCU не принципиален, нужно было лишь собирать данные по i2c от ina228 и передавать их по uart/wifi/bt.
- детектор звука - датчик с компаратором LM393 и электретным капсулем

Замеры каскадного режима работы

глубокий сон






Рисунок 19 – Каскадный режим работы: пробуждение по звуковому событию и инференс WakeNet9 ($\approx 55\text{--}70$ мА) с возвратом в глубокий сон (≈ 1.95 мА)

Разделение доменов



Потребление отладочной платы

ИТМО



+ usb phy
программно не
отключается(

inefficient
ldo :(
(~0.15ma)