

ІТМО

Разработка энергоэффективной системы распознавания голосовых команд с использованием нейронных сетей для устройств интернета вещей

Выполнил:

студент группы Р3431
Дворкин Борис Александрович

Научный руководитель:

Быковский Сергей Вячеславович

Актуальность и проблематика

Голосовое управление в IoT требует одновременно двух несовместимых вещей



**Непрерывное
прослушивание**

Устройство всегда готово
принять голосовую команду

звуковой тракт работает 24/7



ПРОТИВОРЕЧИЕ



**Автономность от
батареи**

Ограниченный энергетический
бюджет устройства

без частого обслуживания и проводов

следствие — избыточное энергопотребление и потеря автономности батарейных IoT-устройств

Цель и критерии достижимости

ЦЕЛЬ РАБОТЫ

Снижение энергопотребления устройств интернета вещей с функцией голосового управления за счёт применения каскадного метода управления режимами работы и использования квантизированных нейронных сетей для распознавания ключевых слов голосовых команд.

КРИТЕРИИ ДОСТИЖИМОСТИ

C1	Точность распознавания <i>MLPerf Tiny</i>	$\geq 90 \%$
C2	Размер модели <i>внутренний SRAM</i>	$\leq 128 \text{ КБ}$
C3	Потеря точности от квантизации	$\leq 1 \%$
C4	Латентность инференса	$\leq 500 \text{ мс}$
C5	Снижение средней мощности	$\geq \times 100$

итоговые значения по каждому критерию приводятся в выводах работы

- 
- 
1. Провести анализ существующих методов и систем распознавания ключевых слов голосовых команд, выявить основные источники избыточного энергопотребления в режиме непрерывного голосового мониторинга и сформулировать требования к энергоэффективному решению.
 2. Предложить каскадную архитектуру детекции ключевых слов, разделяющую процесс на этапы с возрастающей вычислительной сложностью и управлением режимами энергопотребления, допускающую реализацию на различных микроконтроллерных платформах.
 3. Исследовать влияние методов квантизации (PTQ, QAT) на точность, размер и вычислительную сложность нейросетевой модели классификатора ключевых слов.
 4. Провести экспериментальную апробацию предложенного подхода на микроконтроллерной платформе ESP32-S3 с использованием лабораторного стенда.
 5. Выполнить сравнительную оценку энергоэффективности предложенного решения относительно базовых сценариев и проанализировать вклад каждого компонента архитектуры в общее снижение энергопотребления.

Задача 1. Анализ предметной области ИТМО


ВЫЯВЛЕНО

Источники избыточного потребления

- 1 Непрерывный захват аудио**
 - звуковой тракт всегда активен
- 2 Постоянная активность ЦПУ**
 - нет переходов в глубокий сон
- 3 Избыточная сложность моделей**
 - эталоны в литературе неоптимальны

Из литературы: 85% энергии конвейера — захват + извлечение признаков, не инференс

ПРОАНАЛИЗИРОВАНО · ВЫБОР ПЛАТФОРМЫ




СФОРМУЛИРОВАНО

Требования к решению

- 1 Снижение средней мощности**
 - кратно ниже непрерывного инференса
- 2 Точность $\geq 90\%$ при компактной модели**
 - MLPerf Tiny:
 - потеря FP32 $\rightarrow$ INT8 $\leq 1\%$
- 3 Латентность отклика — секунды**
 - интерактивный голосовой UX
- 4 Открытость и переносимость**
 - открытый стек
 - любой МК с deep sleep



Разрыв в энергоэффективности с ASIC компенсируется **каскадной архитектурой** и **квантизацией модели**. → **Задачи 2-3**

Задача 2. Каскадная архитектура





Каскадная архитектура: каждый этап активируется только при необходимости

Задача 3. Подбор архитектуры классификатора



Задача 3. Квантизация: PTQ или QAT?



ВЫВОДЫ



PTQ $\approx$ QAT для INT8

медиана разности $+0,05$ п.п.,
98% моделей в коридоре $\pm 0,65$



Потеря $< 1\%$


оба метода укладываются в
требование СЗ относительно
FP32



Выбран PTQ

при равной точности — выигрыш
по времени развёртывания


Выбор финальной модели классификатора



ВЫВОДЫ

- Финальная: 104 × 5**
точность 96,12 %
при 149,6 мДж на один вывод
- Альтернатива 176 × 7**
выше всего на 0,17 п.п.,
но в 3 раза дороже по энергии
- Колено по энергии**
после 150 мДж прирост точности
экономически не оправдан
- Критерии C1–C4 выполнены**
точность ≥ 90 %,
размер ≤ 128 КБ, потеря < 1 п.п.,
латентность < 500 мс

Задача 4. Лабораторный стенд



Видео работы устройства

СТЕНД ДЛЯ АПРОБАЦИИ НА ESP32-S3


Монитор питания с разрешением **единиц микроампер** и независимый контур записи измерений — для регистрации **тока** по фазам программы без влияния на измеряемое устройство.

КОНТУР 1 · ИЗМЕРЯЕМОЕ УСТРОЙСТВО



----- РАЗДЕЛЬНЫЕ ШИНЫ ПИТАНИЯ · ОБЩАЯ ЗЕМЛЯ (ЗВЕЗДА) -----


КОНТУР 2 · ЗАПИСЬ ИЗМЕРЕНИЙ




Задача 5. Профиль тока каскада

DEEP SLEEP RECORD INFERENCE SHUTDOWN I(t) среднее по фазе
HW BOOT MFCC RESULT I(t) сырой

Мгновенный ток I(t) за цикл




Средний ток по фазам FSM



Ключевые наблюдения

- 1 Полный цикл – 9 секунд**
от пробуждения до
возврата в сон
- 2 Сон – 6ма**
базовая “полка” потребления
отладочной платы
- 3 Пик – 110ма**
во время аппаратной
инициализации
- 4 Длительность важнее пика**
основное потребление - при
длительной записи аудио и
инициализации

Задача 5. Декомпозиция энергобюджета ИТМО



ВЫЧИСЛЕНИЯ

19,2 %

извлечение признаков 9,0 %
инференс 10,2 %

СЕРВИСНЫЕ ЭТАПЫ

80,8 %


инициализация 34,9 %
захват аудио 37,4 % · переход в сон 8,5 %

В ЛИТЕРАТУРЕ
вычисления — главный потребитель энергии конвейера распознавания команд



В ЭТОЙ РАБОТЕ
вычисления — лишь 19 %; доминируют сервисные этапы (81 %) → переворот приоритетов оптимизации

Автономная работа от АКБ



От стенда к продукту

- 1 Минимизировать избыточность компонентов**
сон 6 мА → десятки мкА
- 2 MEMS-микрофон с пробуждением по звуку**
детектор всегда активен, экономит энергию
- 3 Стабилизатор с минимальным током покоя**
не «съедает» батарею во сне
- 4 Свои печатные платы для тактирования и питания**
оптимизация разводки и трасс

→ автономность выше в 40 раз

Каскадная архитектура + аппаратная оптимизация → почти 2 года автономии.


КРИТЕРИИ ДОСТИЖИМОСТИ

№	КРИТЕРИЙ	ТРЕБ.	РЕЗУЛЬТАТ
C1	Точность	≥ 90 %	96,12 %
C2	Размер модели	≤ 128 КБ	101 КБ
C3	Потеря от квант.	≤ 1 п.п.	−0,3 п.п.
C4	Латентность	≤ 500 мс	460 мс
C5	Снижение мощности	≥ ×100	×530

НАУЧНАЯ НОВИЗНА

- 1Систематическое исследование архитектур
134 модели, 239 точек, доверит. интервал Уилсона
- 2Декомпозиция энергобюджета каскада
выявлен доминирующий вклад сервисных этапов
- 3Сравнение PTQ vs QAT на большой выборке
PTQ ≈ QAT для INT8 — статистическое подтверждение

ЦЕЛЬ РАБОТЫ ДОСТИГНУТА



Сокращение инициализации

приоритет №1

RTC SRAM, light sleep, перенос инициализации на ULP-сопроцессор → 35 % бюджета цикла




Промышленная плата

Регулятор ультранизкого тока покоя, MEMS wake-on-sound микрофон вместо LM393 → автономность на годы



Дистилляция знаний

уменьшение модели при сохранении точности, дополнительная экономия энергии инференса



Верификация на других платформах



STM32U5, nRF52840 – подтверждение переносимости методики

**Спасибо
за внимание!**


iT's **MO** *re than a*
UNIVERSITY

tg: @worthant
mail: boris0indeed@gmail.com


Препроцессинг аудио



Конвейер обучения моделей




Компонентная диаграмма ПО




Послойное профилирование инференса

ИТМО




Послойное профилирование инференса

ИТМО



Потребление отладочной платы



+ usb phy
программно не
отключается(

inefficient
ldo :(
(~0.15ma)

Структура ошибок




f104_b5 PTQ INT8 — test acc 96.12%



f104_b5 QAT INT8 — test acc 95.74%



Размещение компонентов на тестовом стенде



- inmp441 - i2s mems-микрофон
- ina228 - цифровой “мультиметр”
- esp32-s3-zero - отладочная плата для удобной работы с чипом esp32-s3 (usb phy, кнопки reset/boot, монтажные ножки)
- s3 имеет архитектуру Xtensa LX7 с поддержкой SIMD (128-битные регистры, можем одной инструкцией делать 8 умножений по 8 пар при INT8 квантизации!)
- esp32-c3-super-mini - отладочная плата для удобной работы с чипом esp32-c3.
- c3 имеет открытую архитектуру RISC-V. В данном случае используемый MCU не принципиален, нужно было лишь собирать данные по i2c от ina228 и передавать их по uart/wifi/bt.
- детектор звука - датчик с компаратором LM393 и электретным капсулем

Разделение доменов

